

Previsão de falhas e análise preditiva

Guia prático do aluno - Dia 3

Neste laboratório, você aprenderá a transformar uma sequência de medições em uma estimativa de risco futuro. O objetivo não é adivinhar o futuro, mas reconhecer padrões de degradação, calcular uma probabilidade de falha e usar a IA generativa para explicar os fatores que justificam essa previsão.

Tema	Previsão de falhas e análise preditiva
Modelo preditivo	Regressão logística com dados históricos controlados
Apoio da IA	Explicação das evidências, fatores de risco, ações e limitações
Resultado visual	Linha do tempo das métricas, probabilidade por janela e momento de ação

A proposta do Dia 3 completa uma sequência de aprendizagem: no Dia 1, explicamos falhas que já aconteceram; no Dia 2, detectamos desvios que estavam acontecendo; no Dia 3, estimamos se uma degradação recente indica risco de falha nas próximas janelas.

Ideia central

O modelo preditivo calcula a probabilidade. A IA generativa explica os fatores. O painel visual permite decidir quando investigar ou agir.

Material didático para uso em laboratório. Os números, limites e dados do exercício foram definidos para fins educacionais e não devem ser adotados diretamente como parâmetros de produção.

Conteúdo do material

- 1. Da explicação de falhas à previsão de falhas
- 2. O problema preditivo: alvo, horizonte e janela
- 3. Como a solução combina Machine Learning e IA generativa
- 4. Dados históricos, características e rótulos
- 5. Preparação e validação do laboratório
- 6. Treinamento e avaliação do modelo
- 7. Cenário 1: crescimento gradual da latência
- 8. Cenário 2: crescimento gradual da taxa de erro
- 9. Cenário 3: crescimento do volume de logs
- 10. Cenário 4: pico transitório com recuperação
- 11. Como interpretar a explicação da IA
- 12. Desafio final: agir antes da falha
- 13. Como adaptar o método a outra aplicação
- 14. Limitações e cuidados para uso em produção
- 15. Glossário e referência rápida de comandos

Como utilizar este material

O ambiente do laboratório já deverá estar preparado pelo professor. Durante a aula, você não precisará criar toda a infraestrutura nem executar prompts de implementação. Seu trabalho será compreender o processo, executar os cenários, interpretar os painéis e justificar decisões preventivas.

- Execute os comandos na ordem indicada.
- Observe os valores de cada janela, e não apenas o resultado final.
- Separe fatos medidos, interpretação do modelo, explicação da IA e causa confirmada.
- Registre em qual janela você consideraria necessário investigar ou mitigar.
- Não trate uma probabilidade como certeza.
- Ao final de cada cenário, responda às perguntas de avaliação antes de avançar.

Regra de segurança

Nunca coloque chaves de API no código, no relatório, no Git ou em capturas de tela. Quando a OpenAI não estiver configurada, o laboratório deverá continuar funcionando com uma explicação determinística.

1. Da explicação de falhas à previsão de falhas

Os três dias tratam o mesmo sistema em momentos diferentes. Essa diferença temporal é essencial para compreender por que detecção e previsão não são a mesma coisa.

Dia	Pergunta	Momento da análise	Saída
Dia 1	O que falhou e como os logs explicam a falha?	Depois da falha	Diagnóstico e explicação
Dia 2	O comportamento atual está diferente da baseline?	Durante o desvio	Anomalia detectada
Dia 3	A sequência recente indica risco de falha futura?	Antes da falha	Probabilidade e ação preventiva

No Dia 2, uma janela isolada podia ser suficiente para detectar uma anomalia. No Dia 3, uma única janela não conta toda a história. Precisamos analisar uma sequência: o valor está crescendo, permanece elevado ou voltou ao normal?

Medições históricas	Características de tendência	Modelo preditivo	Probabilidade	Explicação da IA	Ação preventiva
---------------------	------------------------------	------------------	---------------	------------------	-----------------

Anomalia não é previsão

Uma anomalia informa que algo se afastou do normal. Uma previsão estima a chance de esse padrão evoluir para uma falha dentro de um horizonte definido.

Pausa para análise

1. Uma aplicação pode apresentar uma anomalia e se recuperar sem falhar?
2. Uma aplicação pode ainda estar respondendo HTTP 200 e, mesmo assim, apresentar risco crescente?
3. Por que uma sequência de três ou quatro janelas oferece mais contexto do que uma medição isolada?

2. O problema preditivo: alvo, horizonte e janela

Um modelo preditivo precisa responder a uma pergunta precisa. “A aplicação vai falhar?” é vago. Precisamos definir o que conta como falha e em quanto tempo queremos antecipá-la.

2.1 Alvo da previsão

Neste laboratório, o alvo será representado pelo campo abaixo:

```
{
  "failureWithinNext2Windows": true
}
```

O valor verdadeiro indica que, observando o estado atual e as janelas anteriores, ocorrerá uma falha em uma das duas próximas janelas.

2.2 Horizonte preditivo

O horizonte será de duas janelas. Se cada janela representa um ciclo de observação, a pergunta operacional será:

Pergunta do laboratório

Com base nas últimas janelas, existe probabilidade relevante de falha nas próximas duas janelas?

2.3 Definição didática de falha

Para gerar rótulos no conjunto de dados, uma janela será marcada como falha quando pelo menos uma das condições abaixo ocorrer:

- taxa de erro igual ou superior a 50%;
- latência p95 igual ou superior a 1.500 ms;
- falha do health check, quando o cenário a utilizar.

Atenção

Esses limites foram escolhidos para tornar o laboratório reproduzível. Em uma aplicação real, os limites devem ser definidos com SLOs, experiência do usuário, capacidade do sistema e histórico de incidentes.

2.4 O que é uma janela?

Uma janela reúne várias requisições realizadas em um mesmo período. Em vez de prever com base em uma única chamada, o laboratório calcula métricas agregadas por janela.

Janela	Latência p95	Taxa de erro	Logs/requisição	Situação
J1	12 ms	0%	2	Normal
J2	90 ms	2%	3	Início de degradação
J3	250 ms	8%	5	Risco crescente
J4	520 ms	18%	8	Ação recomendada
J5	1.700 ms	55%	13	Falha

3. Como a solução combina Machine Learning e IA generativa

O laboratório utiliza duas formas de IA com responsabilidades diferentes. Essa separação é uma decisão de arquitetura e também uma medida de confiabilidade.

Componente	Responsabilidade	Não deve fazer
Modelo preditivo	Transformar características numéricas em probabilidade de falha.	Escrever explicações livres ou inventar causas.
IA generativa	Explicar a previsão, os fatores de risco, as ações e as limitações.	Alterar a probabilidade, o rótulo ou o limiar.
Painel visual	Mostrar a evolução temporal e apoiar a decisão humana.	Ocultar incertezas ou tratar previsão como certeza.

Histórico	Features	Regressão logística	Probabilidade	Top fatores	LLM explica
-----------	----------	---------------------	---------------	-------------	-------------

3.1 Por que regressão logística?

A regressão logística é adequada ao laboratório porque trabalha com dados tabulares, produz uma probabilidade entre 0 e 1, é rápida e permite examinar a influência das características. Ela funciona como uma baseline de Machine Learning antes de modelos mais complexos.

```
{
  "failureProbability": 0.82,
  "predictedFailure": true,
  "threshold": 0.70,
  "predictionHorizon": "next_2_windows"
}
```

3.2 O que significa 82%?

O valor representa a estimativa do modelo para um padrão semelhante aos exemplos usados no treinamento. Não significa que a falha acontecerá com certeza, nem que 82 de 100 execuções idênticas necessariamente falharão no ambiente real.

Probabilidade não é certeza

Uma previsão deve orientar investigação e mitigação. Ela não substitui evidências operacionais, conhecimento do sistema ou decisão humana.

3.3 Limiar de decisão

O laboratório utilizará 0,70 como limiar principal. O painel também mostrará uma faixa intermediária para apoiar a tomada de decisão.

Probabilidade	Leitura didática	Ação sugerida
Abaixo de 0,40	Risco baixo	Continuar observando
De 0,40 a 0,69	Atenção	Investigar sinais e logs
0,70 ou mais	Falha provável no horizonte	Aplicar mitigação preventiva

4. Dados históricos, características e rótulos

Modelos preditivos aprendem com exemplos históricos. Como o projeto didático não possui meses de telemetria e incidentes rotulados, o laboratório utiliza sequências sintéticas, controladas e reproduzíveis.

4.1 O que significa dado sintético?

É um dado gerado artificialmente para representar padrões conhecidos: estabilidade, degradação gradual, erro crescente, ruído de logs e recuperação. Ele é útil para aprender o processo, mas não comprova que o modelo funcionará em produção.

4.2 Características utilizadas

Característica	O que representa	Exemplo
currentLatencyRatio	Latência atual dividida pela baseline.	4,2 vezes a baseline
latencySlope3	Inclinação da latência nas últimas três janelas.	+180 ms por janela
currentErrorRate	Taxa de erro na janela atual.	18%

Característica	O que representa	Exemplo
errorRateSlope3	Crescimento recente da taxa de erro.	+6 pontos percentuais por janela
currentLogRatio	Logs por requisição divididos pela baseline.	3,5 vezes a baseline
logSlope3	Crescimento dos logs nas últimas três janelas.	+2,5 linhas por janela
consecutiveDegradedWindows	Quantidade de janelas consecutivas degradadas.	3

4.3 Do histórico para uma feature

Considere a sequência de latência p95 abaixo:

```
100 ms → 250 ms → 500 ms
```

O modelo não recebe apenas a lista. A engenharia de características transforma a sequência em valores mais úteis:

```
{
  "currentLatencyP95Ms": 500,
  "latencyChange": 250,
  "latencySlope3": 200
}
```

4.4 O risco de vazamento de dados

O modelo só pode usar informações disponíveis no momento da previsão. Ele não pode receber métricas das janelas futuras nem dividir aleatoriamente janelas da mesma sequência entre treino e teste.

Vazamento temporal

Se janelas da mesma sequência aparecem no treino e no teste, o modelo pode memorizar partes do mesmo incidente. A avaliação parecerá melhor do que realmente é.

Por isso, o laboratório separa sequências completas: algumas para treinamento e outras para teste.

5. Preparação e validação do laboratório

O professor já terá preparado o código e os cenários. Antes de iniciar, valide o ambiente para evitar que uma falha de instalação seja confundida com uma falha prevista pelo modelo.

5.1 Entrar no projeto

```
cd pipeline-guardian-agent-demo
npm ci
```

5.2 Executar os testes do Dia 3

```
npm run test:day3
```

Os testes devem validar, entre outros pontos: geração determinística dos dados, cálculo das features, separação por sequência, treinamento, previsão, fallback sem OpenAI, segurança dos relatórios e comportamento dos quatro cenários.

5.3 Preparar dados e modelo

```
npm run day3:prepare
```

Esse comando deverá executar as etapas abaixo:

- gerar o histórico sintético com semente fixa;
- montar exemplos de treinamento sem usar o futuro nas features;
- separar sequências completas entre treino e teste;
- padronizar as características com estatísticas do conjunto de treino;
- treinar a regressão logística;
- avaliar o modelo no conjunto de teste;
- salvar o modelo e gerar um painel de avaliação.

5.4 Arquivos gerados

Arquivo	Finalidade
reports/day-3/training-summary.json	Resumo do conjunto, divisão, métricas e parâmetros.
reports/day-3/model.json	Pesos, intercepto, estatísticas de padronização e limiar.
reports/day-3/model-evaluation.html	Painel visual com matriz de confusão, precision, recall e limitações.

Abrir o painel de avaliação

```
xdg-open reports/day-3/model-evaluation.html
```

Pausa para análise

1. O conjunto de teste contém sequências que não foram usadas no treinamento?
2. Qual é o recall do modelo?
3. Qual é a precision?
4. Existem falsos positivos? Existem falsos negativos?
5. Qual erro seria mais grave para o contexto de prevenção de falhas?

6. Treinamento e avaliação do modelo

6.1 Matriz de confusão

A matriz de confusão organiza quatro resultados possíveis.

Resultado	Significado no laboratório
Verdadeiro positivo	O modelo previu falha e a falha ocorreu no horizonte.
Falso positivo	O modelo previu falha, mas a sequência se recuperou.
Verdadeiro negativo	O modelo previu baixo risco e não houve falha.
Falso negativo	O modelo informou baixo risco, mas a falha ocorreu.

6.2 Precision e recall

Métrica	Pergunta respondida	Risco quando é baixa
Precision	Das previsões de falha, quantas realmente antecederam falha?	Muitos alertas falsos e perda de confiança.
Recall	Das situações que antecederam falha, quantas foram previstas?	Falhas relevantes passam sem alerta.

A acurácia isolada não é suficiente. Em um conjunto com muitas janelas normais, um modelo que sempre prevê “normal” pode ter boa acurácia e ainda ser inútil para prevenir falhas.

6.3 Avaliação orientada ao negócio

O melhor limiar depende do custo de cada erro. Uma aplicação crítica pode priorizar recall, aceitando mais investigações. Um sistema com custo alto de intervenção pode exigir maior precision.

Discussão

O modelo não é avaliado apenas por uma métrica matemática. A decisão depende do custo de agir sem necessidade e do custo de não agir antes de uma falha.

7. Cenário 1: crescimento gradual da latência

Este cenário representa uma degradação progressiva. A aplicação continua respondendo durante as primeiras janelas, mas a latência cresce de forma persistente até ultrapassar o limite de falha.

7.1 Padrão injetado

```
12 ms → 90 ms → 240 ms → 520 ms → 900 ms → 1.700 ms
```

O código do cenário acrescenta atraso progressivo a cada janela. O objetivo não é esconder a implementação, mas relacionar uma alteração controlada ao comportamento observado.

Trecho didático simplificado

```
const latencyByWindow = [12, 90, 240, 520, 900, 1700];
const latencyP95Ms = latencyByWindow[windowIndex];
```

7.2 Executar o cenário

```
npm run day3:scenario -- latency-growth
```

```
xdg-open reports/day-3/scenarios/latency-growth/prediction-report.html
```

7.3 O que observar no painel

- a curva de latência deve crescer em várias janelas consecutivas;
- a probabilidade deve subir antes da janela de falha;

- o limiar de 70% deve aparecer no gráfico;
- a janela real de falha deve ser marcada separadamente da primeira previsão positiva;
- latencySlope3 e currentLatencyRatio devem aparecer entre os principais fatores.

7.4 Leitura por janela

Janela	Comportamento provável	Decisão esperada
J1	Latência próxima da baseline.	Observar.
J2	Primeiro aumento, ainda com pouca persistência.	Observar e registrar.
J3	Tendência crescente confirmada.	Investigar.
J4	Probabilidade pode ultrapassar o limiar.	Mitigar antes da falha.
J5	Risco elevado, ainda antes da janela final.	Ação imediata.
J6	Limite didático de falha atingido.	A previsão já deveria ter ocorrido.

Avaliação do cenário: crescimento gradual da latência

Elemento	Leitura esperada
Resultado visual	A linha temporal deve mostrar crescimento contínuo e a probabilidade deve ultrapassar o limiar antes da falha real.
Conclusão técnica	O modelo está reconhecendo persistência e inclinação, não apenas uma latência alta isolada.
Cuidado de interpretação	Uma tendência sintética não garante que o mesmo padrão anteceda falhas reais. Investigue CPU, I/O, dependências e mudanças de código antes de afirmar a causa.

Pausa para análise

1. Em qual janela a probabilidade entrou na faixa de atenção?
2. Em qual janela ultrapassou 70%?
3. Quantas janelas de antecedência o modelo ofereceu?
4. Qual fator teve maior contribuição?
5. Que ação preventiva seria adequada antes da falha?

8. Cenário 2: crescimento gradual da taxa de erro

Neste cenário, a maioria das requisições ainda funciona no início. A taxa de erro cresce gradualmente até caracterizar falha. O health check pode continuar saudável, mostrando que disponibilidade do processo não garante confiabilidade da operação.

8.1 Padrão injetado

0% → 3% → 8% → 18% → 35% → 60%

Trecho didático simplificado

```
const errorRateByWindow = [0, 0.03, 0.08, 0.18, 0.35, 0.60];
const errorRate = errorRateByWindow[windowIndex];
```

8.2 Executar o cenário

```
npm run day3:scenario -- error-growth
```

```
xdg-open reports/day-3/scenarios/error-growth/prediction-report.html
```

8.3 O que observar no painel

- a taxa de erro deve crescer sem saltar imediatamente para 100%;
- errorRateSlope3 deve aumentar o risco;
- a probabilidade deve subir enquanto ainda existe uma parcela de requisições bem-sucedidas;
- a análise da IA deve diferenciar erro intermitente de indisponibilidade total;
- o painel deve mostrar a janela na qual o erro atinge o limite de falha de 50%.

Avaliação do cenário: crescimento gradual da taxa de erro

Elemento	Leitura esperada
Resultado visual	A probabilidade deve subir antes de a taxa de erro atingir 50%, usando valor atual, inclinação e persistência.
Conclusão técnica	A operação está se tornando menos confiável. O modelo deve antecipar o momento em que a maioria das chamadas ainda funciona, mas o padrão indica deterioração.
Cuidado de interpretação	A taxa de erro não identifica sozinha a causa. Ela pode refletir código, dependência externa, dados inválidos, timeout ou saturação.

Pausa para análise

1. O modelo reagiu ao valor atual ou principalmente à tendência?
2. Qual é a diferença entre 18% de erro e falha total?
3. Que logs você consultaria primeiro?
4. Qual seria o impacto de um falso negativo neste cenário?
5. Qual mitigação poderia reduzir o risco sem desligar toda a aplicação?

9. Cenário 3: crescimento do volume de logs

O aumento de logs pode anteceder uma falha quando representa retries, loops, repetição de operações ou processamento desnecessário. Neste laboratório, o volume crescente de logs aparece antes do aumento posterior da latência.

9.1 Padrão injetado

```
2 → 3 → 6 → 11 → 20 → 32 linhas por requisição
```

Trecho didático simplificado

```
const logsPerRequestByWindow = [2, 3, 6, 11, 20, 32];
const logLinesPerRequest = logsPerRequestByWindow[windowIndex];
```

9.2 Executar o cenário

```
npm run day3:cenario -- log-growth
```

```
xdg-open reports/day-3/scenarios/log-growth/prediction-report.html
```

9.3 O que observar no painel

- o volume de logs deve crescer antes do limite de falha;
- logSlope3 e currentLogRatio devem aparecer entre os fatores de risco;
- a probabilidade não deve subir apenas porque existe um log adicional;
- o painel deve mostrar quando o crescimento se torna persistente;
- a IA deve tratar excesso de logs como evidência operacional, não como causa confirmada.

Avaliação do cenário: crescimento do volume de logs

Elemento	Leitura esperada
Resultado visual	A probabilidade deve aumentar quando o crescimento se torna persistente e associado aos padrões aprendidos de degradação.
Conclusão técnica	Logs podem funcionar como sinal antecedente. O modelo aprende que crescimento contínuo, e não um pequeno aumento isolado, aparece antes de falhas nos exemplos de treino.
Cuidado de interpretação	Correlação não prova causalidade. Os logs podem crescer por mudança de nível, erro repetido, retry ou instrumentação inadequada.

Pausa para análise

1. O volume de logs aumentou antes da latência?
2. Qual é a diferença entre sinal antecedente e causa?
3. Que eventos estruturados você procuraria?
4. Como um aumento de logs pode elevar custos e dificultar incidentes?
5. Que mudança preventiva você proporia?

10. Cenário 4: pico transitório com recuperação

Este é o cenário mais importante para discutir falso positivo. A latência apresenta um pico relevante, mas as janelas seguintes mostram recuperação. Nem toda anomalia evolui para falha.

10.1 Padrão injetado

```
10 ms → 12 ms → 500 ms → 80 ms → 15 ms → 11 ms
```

Trecho didático simplificado

```
const latencyByWindow = [10, 12, 500, 80, 15, 11];
const latencyP95Ms = latencyByWindow[windowIndex];
```

10.2 Executar o cenário

```
npm run day3:scenario -- transient-spike
```

```
xdg-open reports/day-3/scenarios/transient-spike/prediction-report.html
```

10.3 O que observar no painel

- a latência deve subir em uma janela e cair nas seguintes;
- a probabilidade pode entrar na faixa de atenção, mas não deve permanecer elevada;
- a inclinação recente deve mudar de positiva para negativa;
- o cenário não deve ser rotulado como falha dentro do horizonte;
- a explicação da IA deve reconhecer recuperação e evitar afirmar falha inevitável.

Avaliação do cenário: pico transitório com recuperação

Elemento	Leitura esperada
Resultado visual	O modelo deve evitar uma previsão persistente de falha. A probabilidade deve cair quando as janelas seguintes confirmarem recuperação.
Conclusão técnica	A sequência demonstra por que tendência e persistência são mais informativas do que um único valor extremo.
Cuidado de interpretação	O modelo ainda pode gerar atenção temporária. Isso não é necessariamente erro: investigar um pico relevante pode ser adequado, desde que a ação seja proporcional.

Pausa para análise

1. Qual foi a maior probabilidade do cenário?
2. Ela ultrapassou 70%? Por quanto tempo?
3. O modelo gerou um falso positivo?
4. Qual evidência confirmou a recuperação?
5. Como evitar alert fatigue sem ignorar picos importantes?

11. Como interpretar a explicação da IA

A IA generativa recebe a previsão já calculada. Ela não pode alterar a probabilidade, o limiar, o resultado ou os fatores numéricos.

11.1 Estrutura da entrada

```
{
  "failureProbability": 0.82,
  "predictedFailure": true,
  "predictionHorizon": "next_2_windows",
  "topFactors": [
    {"feature": "latencySlope3", "direction": "increases_risk"},
    {"feature": "errorRateSlope3", "direction": "increases_risk"}
  ],
  "recentWindows": ["J2", "J3", "J4"]
}
```

11.2 Estrutura da saída

```
{
  "summary": "O risco de falha nas próximas duas janelas é elevado.",
  "evidence": ["A latência cresceu em três janelas consecutivas."],
  "interpretation": "O padrão é persistente, não um pico isolado.",
  "recommendedActions": ["Investigar o caminho de /api/report."],
  "limitations": ["Os dados do laboratório são sintéticos."]
}
```

11.3 Separar cinco níveis de interpretação

Nível	Exemplo
Fato	A latência p95 passou de 240 ms para 520 ms.
Resultado do modelo	A probabilidade calculada foi 82%.
Interpretação	O padrão é crescente e persistente.
Hipótese	Pode existir espera adicional, saturação ou dependência lenta.
Causa confirmada	Somente após inspeção de código, logs e infraestrutura.

Critério de qualidade

Uma boa explicação cita fatos e limitações. Uma explicação ruim transforma correlação em causa ou trata probabilidade como certeza.

11.4 Executar sem OpenAI

```
unset OPENAI_API_KEY
npm run day3:scenario -- latency-growth
```

O relatório deve continuar sendo gerado com fallback determinístico. A probabilidade não muda porque a explicação não participa do modelo.

11.5 Executar com OpenAI

```
read -s -p "OPENAI_API_KEY: " OPENAI_API_KEY
echo
export OPENAI_API_KEY
npm run day3:scenario -- latency-growth
```

Compare a explicação do modelo com o fallback. A decisão preditiva deve permanecer exatamente igual.

12. Desafio final: agir antes da falha

O desafio não será uma disputa entre grupos. Cada aluno ou equipe aplicará o processo aprendido em um caso novo, sem conhecer antecipadamente se a sequência terminará em falha ou recuperação.

12.1 Objetivo

Você deverá acompanhar a evolução por janelas, identificar o primeiro momento em que existe evidência suficiente para agir, justificar uma ação preventiva e avaliar o resultado após uma mitigação simulada.

12.2 Casos disponíveis

Caso	Descrição não revelada durante a execução
case-a	Combinação gradual de latência e erros.
case-b	Crescimento de logs com degradação posterior.
case-c	Pico relevante seguido de recuperação.

O professor poderá atribuir um caso ou permitir escolha. A descrição completa só deve ser consultada após a análise.

12.3 Executar o caso

```
npm run day3:challenge -- case-a
```

```
xdg-open reports/day-3/challenges/case-a/prediction-report.html
```

12.4 Procedimento obrigatório

- Observe a linha temporal sem abrir o código do cenário.
- Registre a probabilidade em cada janela.
- Classifique cada janela como observar, investigar ou mitigar.
- Identifique os três principais fatores de risco.
- Leia a explicação da IA e destaque fatos, hipóteses e limitações.
- Escolha a primeira janela em que você agiria.
- Justifique uma ação preventiva concreta.
- Somente depois revele o resultado real do caso.

12.5 Ficha de decisão por janela

Janela	Probabilidade	Faixa	Fatores principais	Decisão	Justificativa
J1					
J2					
J3					
J4					
J5					
J6					

12.6 Revelar o resultado

```
npm run day3:challenge:reveal -- case-a
```

Compare sua decisão com o desfecho. O objetivo não é apenas acertar “falha” ou “não falha”, mas avaliar se a ação foi tomada com antecedência e evidência suficientes.

12.7 Aplicar a mitigação simulada

```
npm run day3:challenge -- case-a --mitigated
```

O painel mitigado deve mostrar como as métricas e a probabilidade se comportam após uma ação preventiva. Compare a sequência original e a mitigada.

12.8 Entregáveis

- ☐ Tabela preenchida com as seis janelas.
- ☐ Primeira janela escolhida para investigação.
- ☐ Primeira janela escolhida para mitigação.
- ☐ Três evidências numéricas.
- ☐ Dois fatores principais do modelo.
- ☐ Uma hipótese técnica e uma limitação.
- ☐ Ação preventiva proposta.
- ☐ Comparação antes e depois da mitigação.
- ☐ Conclusão sobre falso positivo, falso negativo ou previsão correta.

12.9 Critérios de avaliação

Critério	O que será observado	Peso sugerido
Leitura temporal	Analisa a evolução, e não apenas a última janela.	20%
Interpretação do modelo	Explica probabilidade, limiar e fatores.	20%
Uso de evidências	Cita métricas e janelas específicas.	20%
Ação preventiva	Propõe mitigação coerente e proporcional.	20%
Validação	Compara resultado original e mitigado.	20%

Condição de conclusão

A atividade termina quando você consegue justificar quando agir, por que agir e como verificar se a mitigação reduziu o risco.

13. Como adaptar o método a outra aplicação

O laboratório utiliza a rota de relatório do projeto, mas o método é geral. Para aplicar em outro sistema, siga a sequência abaixo.

- Escolha uma operação importante, como checkout, upload, geração de documento, consulta ou execução de agente.
- Defina a falha que deseja antecipar.

- Defina o horizonte: próximas requisições, próximos minutos, próximo lote ou próxima execução.
- Escolha sinais com relação plausível com a falha.
- Colete histórico suficiente e rotule incidentes reais.
- Crie features que representem valor atual, tendência e persistência.
- Separe treino e teste de forma temporal ou por entidade.
- Treine uma baseline simples antes de modelos complexos.
- Avalie precision, recall, falsos positivos e falsos negativos.
- Explique a previsão sem permitir que a LLM altere o resultado.
- Defina ações preventivas e valide o efeito delas.

13.1 Exemplos de sinais por domínio

Domínio	Sinais possíveis	Falha prevista
API	latência, erros, payload, retries	timeout ou indisponibilidade
Pipeline CI/CD	tempo por etapa, retries, flakiness, filas	falha ou atraso do pipeline
Agente de IA	tokens, tool errors, loops, latência	execução incompleta ou custo excessivo
Banco de dados	latência, conexões, locks, filas	saturação ou timeout
Processamento em lote	throughput, backlog, erro por lote	não cumprimento da janela

14. Limitações e cuidados para uso em produção

O laboratório ensina o ciclo preditivo, mas não representa um modelo pronto para produção.

Limitação do laboratório	O que seria necessário em produção
Dados sintéticos	Histórico real de telemetria e incidentes corretamente rotulados.
Poucas features	Seleção baseada em conhecimento do sistema e análise exploratória.
Distribuição estável	Monitoramento de drift de dados e de performance.
Modelo local	Versionamento, registry, deployment e rollback.
Limiar fixo	Calibração conforme custo operacional e SLO.
Explicação por LLM	Avaliação de qualidade, segurança e privacidade.
Cenários conhecidos	Teste em incidentes e padrões inéditos.

14.1 Perguntas antes de colocar em produção

- O rótulo representa uma falha real e relevante?
- O horizonte oferece tempo suficiente para agir?
- Os dados de treino representam diferentes versões e cargas?
- Existe vazamento temporal ou por aplicação?
- Qual é o custo de um falso positivo?
- Qual é o custo de um falso negativo?
- Como o modelo será monitorado e reavaliado?
- Quem toma a decisão final e qual ação é automatizada?

15. Glossário e referência rápida

15.1 Glossário

Termo	Definição
Alvo	Evento que o modelo tenta prever.
Horizonte	Intervalo futuro considerado pela previsão.
Janela	Conjunto de observações agregadas em um período ou ciclo.
Feature	Característica numérica entregue ao modelo.
Rótulo	Resultado conhecido usado no treinamento e avaliação.
Baseline	Referência de comportamento normal ou modelo inicial.
Limiar	Valor usado para converter probabilidade em decisão.
Precision	Proporção de previsões positivas que estavam corretas.
Recall	Proporção das falhas futuras que foram previstas.
Falso positivo	Previsão de falha sem falha no horizonte.
Falso negativo	Falha no horizonte sem previsão positiva.
Drift	Mudança na distribuição dos dados ou na relação com o alvo.
Vazamento	Uso indevido de informação futura ou do conjunto de teste.

15.2 Comandos

Objetivo	Comando
Instalar dependências	<code>npm ci</code>
Testar o Dia 3	<code>npm run test:day3</code>
Gerar dados, treinar e avaliar	<code>npm run day3:prepare</code>
Executar latência crescente	<code>npm run day3:scenario -- latency-growth</code>
Executar erros crescentes	<code>npm run day3:scenario -- error-growth</code>
Executar logs crescentes	<code>npm run day3:scenario -- log-growth</code>
Executar pico transitório	<code>npm run day3:scenario -- transient-spike</code>
Executar todos os cenários	<code>npm run day3:scenario -- all</code>
Executar desafio	<code>npm run day3:challenge -- case-a</code>
Revelar resultado	<code>npm run day3:challenge:reveal -- case-a</code>
Executar versão mitigada	<code>npm run day3:challenge -- case-a --mitigated</code>

15.3 Checklist final de compreensão

- ☐ Consigo diferenciar detecção de anomalia e previsão de falha.
- ☐ Consigo definir alvo e horizonte.
- ☐ Entendo por que as features usam valor atual, tendência e persistência.
- ☐ Consigo explicar o papel da regressão logística.
- ☐ Consigo interpretar probabilidade e limiar.
- ☐ Consigo ler precision, recall e matriz de confusão.
- ☐ Consigo diferenciar fato, hipótese e causa confirmada.
- ☐ Entendo que a LLM explica, mas não calcula a previsão.
- ☐ Consigo escolher uma janela de ação preventiva.
- ☐ Consigo validar o efeito de uma mitigação.

Síntese do Dia 3

Prever falhas não é adivinhar. É definir um evento futuro, transformar histórico em características, estimar risco, explicar evidências, agir com antecedência e medir novamente.

Fim do material.